

Lista 08 - Fundamentos Estatísticos para Ciência dos Dados

Nome: Vinícius de Oliveira Silva

Matrícula: 2013007820

Questão 1

Gerando a matriz L , e os vetores z e x

```
sigma <- matrix( c(4, 9, -14,
                   9, 30, -44,
                   -14, -44, 94),
                 nrow=3,
                 ncol=3)

mu<-as.numeric(c(10,20,-50))

#Matriz L
L<-t(chol(sigma))

#vetor z
z <-rnorm(3, mean=0, sd=1)

#vetor x
x<-mu + L%*%z
```

Gerando uma amostra com 200 registros, calculando o vetor médio e comparando com o vetor esperado:

```
amostra <- matrix(nrow = 200, ncol=3)
for(i in 1:200){
  amostra[i,] <- t(mu + L%*%rnorm(3, mean=0, sd=1))
}

vetorMedio <- apply(amostra, MARGIN = 2, FUN=mean)

print(vetorMedio)
```

```
## [1] 10.08007 20.42356 -51.23353
```

Conforme podemos observar, o vetor medio é bastante proximo do vetor esperado μ .

Estimando a matriz de covariância:

```
getSij <- function(i,j,n,matriz){
  sum<-0
  for(counter in 1:ncol(matriz)){
    sum <- sum + (
      (amostra[counter,i] - vetorMedio[i]) *
      (amostra[counter,j] - vetorMedio[j])
    )
  }

  return(sum/n)
}

#gerando a matriz S:
S <- matrix(nrow = 3, ncol = 3)

for(i in 1:3){
  for(j in 1:3){
    S[i,j] <- getSij(i,j,n=200,matriz=amostra)
  }
}
```

Se subtrairmos Σ de S, podemos ver com clareza o quanto elas são parecidas.

```
## [1] " $\Sigma$  - S = "
```

```
##
##      3.955059   9.012445 -13.99284
##      9.012445  29.953831 -44.01289
##     -13.992843 -44.012892  93.99569
```

Vemos que as diferenças entre a matriz estimada e a matriz geradora dos dados são bem pequenas.

Gerando a matriz de correlação ρ :

```
origVariances <- diag(sigma)

rho <- matrix(nrow = 3, ncol = 3)

for(i in 1:3){
  for(j in 1:3){
    rho[i,j] <- sigma[i,j]/sqrt(origVariances[i] * origVariances[j])
  }
}

print('A matriz de correlação  $\rho$  é:')
```

```
## [1] "A matriz de correlação  $\rho$  é:"
```

```
prmatrix(rho, rowlab=rep("",3), collab=rep("",3))
```

```
##
##  1.0000000  0.8215838 -0.7219949
##  0.8215838  1.0000000 -0.8285679
## -0.7219949 -0.8285679  1.0000000
```

Desejamos agora construir R, uma estimativa da matriz de correlação ρ :

```
approxVariances <- diag(S)
R<- matrix(nrow = 3, ncol = 3)

for(i in 1:3){
  for(j in 1:3){
    R[i,j] <- S[i,j]/sqrt(approxVariances[i] * approxVariances[j])
  }
}

print('A matriz de correlação estimada R é:')
```

```
## [1] "A matriz de correlação estimada R é:"
```

```
prmatrix(R, rowlab=rep("",3), collab=rep("",3))
```

```
##
##  1.0000000 -0.2732191 -0.5140716
## -0.2732191  1.0000000  0.9136294
## -0.5140716  0.9136294  1.0000000
```

Para compararmos as matrizes R e ρ , podemos olhar para o resultado da subtração das duas:

```
## [1] " $\rho$  - R = "
```

```
##
##  0.0000000  1.094803 -0.2079233
##  1.0948029  0.000000 -1.7421973
## -0.2079233 -1.742197  0.0000000
```

Percebemos que as entradas da matriz resultante desta subtração são bastante pequenas, o que indica que as matrizes são bastante similares

Questão 2

```
R11 <- list()
R12 <- list()
R13 <- list()
R21 <- list()
R22 <- list()
R23 <- list()
R31 <- list()
R32 <- list()
R33 <- list()

amostraR <- list(R11, R12, R13, R21, R22, R23, R31, R32, R33)

#repetiremos a simulação 5000 vezes
for (counter in 1:5000){

  #gerando a matriz amostra
  for(i in 1:200){
    amostra[i,] <- t(mu + L*%*%rnorm(3, mean=0, sd=1))
  }

  #matriz de correlacao empirica R
  R <- cor(amostra)

  amostraR[[1]] <- append(amostraR[[1]], R[1,1])
  amostraR[[2]] <- append(amostraR[[2]], R[1,2])
  amostraR[[3]] <- append(amostraR[[3]], R[1,3])
  amostraR[[4]] <- append(amostraR[[4]], R[2,1])
  amostraR[[5]] <- append(amostraR[[5]], R[2,2])
  amostraR[[6]] <- append(amostraR[[6]], R[2,3])
  amostraR[[7]] <- append(amostraR[[7]], R[3,1])
  amostraR[[8]] <- append(amostraR[[8]], R[3,2])
  amostraR[[9]] <- append(amostraR[[9]], R[3,3])
}


k<-1
for(i in 1:3){



  for(j in 1:3){

    #não precisamos calcular a correlação de uma variavel com ela mesma, pois esse valor é sempre 1
    "também não precisamos recalculer a correlação entre as variáveis i e j se i > j, uma vez que a correlação entre i e j é igual a correlação entre j e i"
    if(i<j){
      hist(as.numeric(amostraR[[k]]), main=paste("Histograma da correlação entre as variáveis ", i, " e ", j), xlab = "Valor da correlação")
    }
  }
}
```

```
k<- k+1  
}  
}
```

Histograma da correlação entre as variáveis 1 e 2



Histograma da correlação entre as variáveis 1 e 3**Histograma da correlação entre as variáveis 2 e 3**

```
#transforma uma lista de listas em uma matriz (cada lista é uma coluna)
matrixAmostraR <- (sapply (amostraR, function (x) {length (x) <- 5000; retu
rn (x)}))

#-----Obtendo a matriz R-----
myMean <- function(myArray){
  return (mean(as.numeric(myArray)))
}

matrixExpectedR <- matrix(apply(matrixAmostraR, MARGIN = 2,FUN = myMean), nr
ow = 3, ncol = 3)

#-----
```

A matriz R é portanto:

```
prmatrix(matrixExpectedR, rowlab=rep("",3), collab=rep("",3))
```

```
##
##  1.0000000  0.8203613 -0.7208222
##  0.8203613  1.0000000 -0.8279538
## -0.7208222 -0.8279538  1.0000000
```

Podemos ver que ela é bem parecida com a matriz rho:

```
prmatrix(rho, rowlab=rep("",3), collab=rep("",3))
```

```
##
##  1.0000000  0.8215838 -0.7219949
##  0.8215838  1.0000000 -0.8285679
## -0.7219949 -0.8285679  1.0000000
```

Podemos também calcular os DP de cada r_{ij} da matriz R e montar uma nova matriz contendo esses desvios:

```
dpMatrix <- matrix(nrow = 3, ncol = 3)

amostraIndex<-1
for (i in 1:3){
  for(j in 1:3){
    dpMatrix[i,j] <- sd(as.numeric(amostraR[[amostraIndex]]))
    amostraIndex <- amostraIndex+1
  }
}

prmatrix(rho, rowlab=rep("",3), collab=rep("",3))
```

```
##
##  1.0000000  0.8215838 -0.7219949
##  0.8215838  1.0000000 -0.8285679
## -0.7219949 -0.8285679  1.0000000
```

Questão 3

a) A matriz de correlação ρ de X é dada por:

$$\begin{bmatrix} 1 & 0 & \frac{2}{\sqrt{3.4}} & \frac{2}{\sqrt{3.4}} \\ 0 & 1 & \frac{1}{\sqrt{1.4}} & 0 \\ \frac{2}{\sqrt{3.4}} & \frac{1}{\sqrt{1.4}} & 1 & \frac{-2}{\sqrt{9.4}} \\ \frac{2}{\sqrt{3.4}} & 0 & \frac{-2}{\sqrt{9.4}} & 1 \end{bmatrix}$$

b) $E(X^{(1)}) = (0, 1)$

c) $E(AX^{(1)}) = A \cdot E(X^{(1)}) = \begin{bmatrix} 1 \\ -1 \end{bmatrix} \cdot \begin{bmatrix} 0 & 1 \end{bmatrix} = 1 \cdot 0 + (-1) \cdot 1 = -1$

d) $\text{Cov}(X^{(1)}) \rightarrow$ Basta identificarmos em Σ a submatriz referente a $X^{(1)}$:

$$\hookrightarrow \text{Cov}(X^{(1)}) = \begin{bmatrix} 3 & 0 \\ 0 & 1 \end{bmatrix}$$

$$d) \text{Cov}(AX^{(1)}) \rightarrow \text{Sabemos que } \text{Cov}(AX^{(1)}) = A \text{Cov}(X^{(1)}) A^T = \begin{bmatrix} 1 & -1 \\ 0 & 1 \end{bmatrix} \begin{bmatrix} 3 & 0 \\ 0 & 1 \end{bmatrix} \begin{bmatrix} 1 \\ -1 \end{bmatrix} = 4$$

$$f) E(X^{(2)}) = (0, -1)$$

$$g) E(BX^{(2)}) = B E(X^{(2)}) = \begin{bmatrix} 1 & -1 \\ 1 & 2 \end{bmatrix} \times \begin{bmatrix} 0 \\ -1 \end{bmatrix} = \begin{bmatrix} 1 \times 0 + (-1) \times (-1) \\ 1 \times 0 + 2 \times (-1) \end{bmatrix} = \begin{bmatrix} 1 \\ -2 \end{bmatrix}$$

$$h) \text{Cov}(X^{(2)}) = \begin{bmatrix} 9 & -2 \\ -2 & 4 \end{bmatrix}$$

$$i) \text{Cov}(BX^{(2)}) = B \text{Cov}(X^{(2)}) B^T = \begin{bmatrix} 1 & -1 \\ 1 & 2 \end{bmatrix} \times \begin{bmatrix} 9 & -2 \\ -2 & 4 \end{bmatrix} \times \begin{bmatrix} 1 & 1 \\ -1 & 2 \end{bmatrix} = \begin{bmatrix} 17 & -1 \\ -1 & 17 \end{bmatrix}$$

Questão 4

$$X = (X_1, X_2, X_3)' \quad E(X) = (-1, 0, 2)$$

$$\Sigma = \begin{bmatrix} 1 & -2 & 0 \\ -2 & 5 & 0 \\ 0 & 0 & 2 \end{bmatrix}$$

a)

$$Y_1 = \frac{1}{4} X_1 - \frac{1}{4} X_2 + \frac{1}{2} X_3 \rightarrow c_1' = \begin{bmatrix} \frac{1}{4} & -\frac{1}{4} & \frac{1}{2} \end{bmatrix}$$

$$E(Y_1) = E(c_1' X) = c_1' E(X) = \begin{bmatrix} \frac{1}{4} & -\frac{1}{4} & \frac{1}{2} \end{bmatrix} \begin{bmatrix} -1 \\ 0 \\ 2 \end{bmatrix} = -\frac{1}{4} + 1 = \frac{3}{4}$$

$$\Rightarrow Y_1 \sim N\left(\frac{3}{4}, \frac{2}{8}\right)$$

$$V(Y_1) = c_1' \Sigma c_1 = \begin{bmatrix} \frac{1}{4} & -\frac{1}{4} & \frac{1}{2} \end{bmatrix} \begin{bmatrix} 1 & -2 & 0 \\ -2 & 5 & 0 \\ 0 & 0 & 2 \end{bmatrix} \begin{bmatrix} \frac{1}{4} \\ -\frac{1}{4} \\ \frac{1}{2} \end{bmatrix} = \frac{9}{8}$$

$$b) Y_2 = \frac{1}{4} X_1 + \frac{1}{4} X_2 - \frac{1}{2} X_3 \rightarrow c_2' = \begin{bmatrix} \frac{1}{4} & \frac{1}{4} & -\frac{1}{2} \end{bmatrix}$$

$$E(Y_2) = E(c_2' X) = c_2' \cdot E(X) = \begin{bmatrix} \frac{1}{4} & \frac{1}{4} & -\frac{1}{2} \end{bmatrix} \times \begin{bmatrix} -1 \\ 0 \\ 2 \end{bmatrix} = -\frac{1}{4} - 1 = -\frac{5}{4} \Rightarrow Y_2 \sim N\left(-\frac{5}{4}, \frac{9}{8}\right)$$

$$V(Y_2) = c_2' \Sigma c_2 = \begin{bmatrix} \frac{1}{4} & \frac{1}{4} & -\frac{1}{2} \end{bmatrix} \times \begin{bmatrix} 1 & -2 & 0 \\ -2 & 5 & 0 \\ 0 & 0 & 2 \end{bmatrix} \times \begin{bmatrix} \frac{1}{4} \\ \frac{1}{4} \\ -\frac{1}{2} \end{bmatrix} = \frac{5}{8}$$

c)
Para encontrarmos a distribuição conjunta de $Y = (Y_1, Y_2)$ só nos falta encontrar os elementos da diagonal secundária da matriz de covariância, uma vez que:

$$Y \sim N\left(\begin{bmatrix} \frac{3}{4} \\ -\frac{5}{4} \end{bmatrix}, \begin{bmatrix} \frac{9}{8} & ? \\ ? & \frac{5}{8} \end{bmatrix}\right)$$

Para encontrarmos os elementos faltantes (que são iguais, dado que a matriz é simétrica) basta determinar o resultado de $\begin{bmatrix} c_1' \\ c_2' \end{bmatrix} \times \Sigma \times \begin{bmatrix} c_1 \\ c_2 \end{bmatrix}$:

$$\begin{bmatrix} \frac{1}{4} & -\frac{1}{4} & \frac{1}{2} \\ \frac{1}{4} & \frac{1}{4} & -\frac{1}{2} \end{bmatrix} \times \begin{bmatrix} 1 & -2 & 0 \\ -2 & 5 & 0 \\ 0 & 0 & 2 \end{bmatrix} \times \begin{bmatrix} \frac{1}{4} & \frac{1}{4} \\ -\frac{1}{4} & \frac{1}{4} \\ \frac{1}{2} & -\frac{1}{2} \end{bmatrix} = -\frac{3}{4}$$

Portanto, a distribuição de Y é

$$Y \sim N\left(\begin{bmatrix} \frac{3}{4} \\ -\frac{5}{4} \end{bmatrix}, \begin{bmatrix} \frac{9}{8} & -\frac{3}{4} \\ -\frac{3}{4} & \frac{5}{8} \end{bmatrix}\right)$$

Questão 5

Sabemos que a matriz de covariância Σ tem a seguinte forma:

$$\Sigma = \begin{bmatrix} \sigma_1 & \rho_{12}\sigma_1\sigma_2 & \rho_{13}\sigma_1\sigma_3 \\ \rho_{21}\sigma_2\sigma_1 & \sigma_2 & \rho_{23}\sigma_2\sigma_3 \\ \rho_{31}\sigma_3\sigma_1 & \rho_{32}\sigma_3\sigma_2 & \sigma_3 \end{bmatrix}$$

Se duas variáveis são independentes, sua correlação $\rho = 0$. Desta forma, para sabermos se duas variáveis são independentes, basta observarmos as entradas correspondentes na matriz Σ

a) X_1 e X_2 não são independentes $\Rightarrow \Sigma_{12} \neq 0$

b) X_2 e X_3 são independentes $\Rightarrow \Sigma_{23} = 0$

c) (X_1, X_2) e X_3 são independentes $\Rightarrow \Sigma_{13} = 0$ e $\Sigma_{23} = 0$

d) $(X_1 + X_2)/2$ e X_3 são independentes pois $(X_1 + X_2)/2$ é uma função de X_1 e X_2 , que individualmente são independentes de X_3

e) X_2 e $X_2 + \frac{5X_1}{2} - X_3$ são independentes, pois se usarmos a propriedade

de bilinearidade da covariância, temos que:

$$\begin{aligned} \text{Cov}(X_2, X_2 + \frac{5X_1}{2} - X_3) &= \text{Cov}(X_2, X_2) + \frac{5}{2} \text{Cov}(X_2, X_1) - \text{Cov}(X_2, X_3) \\ &= 5 + \frac{5}{2} \cdot (-2) - 0 = 5 - 5 = 0 \end{aligned}$$

Questão 6

- $E(D^2) = p \rightarrow$ dimensão do vetor X
- $\sqrt{V(D^2)} = p \rightarrow$ dimensão do vetor X
- $D^2 \sim$ Quiquadrado com p graus de liberdade
- Os eixos deste elipsoide são os autovetores da matriz de covariância de X . O comprimento desses eixos é proporcional aos autovalores associados
- e.

```
stiffness = matrix(scan("stiffness.txt"), ncol=5, byrow=T)

x <- stiffness[,1:4]

mu <- apply(x, MARGIN = 2, FUN=mean)

sigma <- cov(x)
```

O vetor esperado μ é:

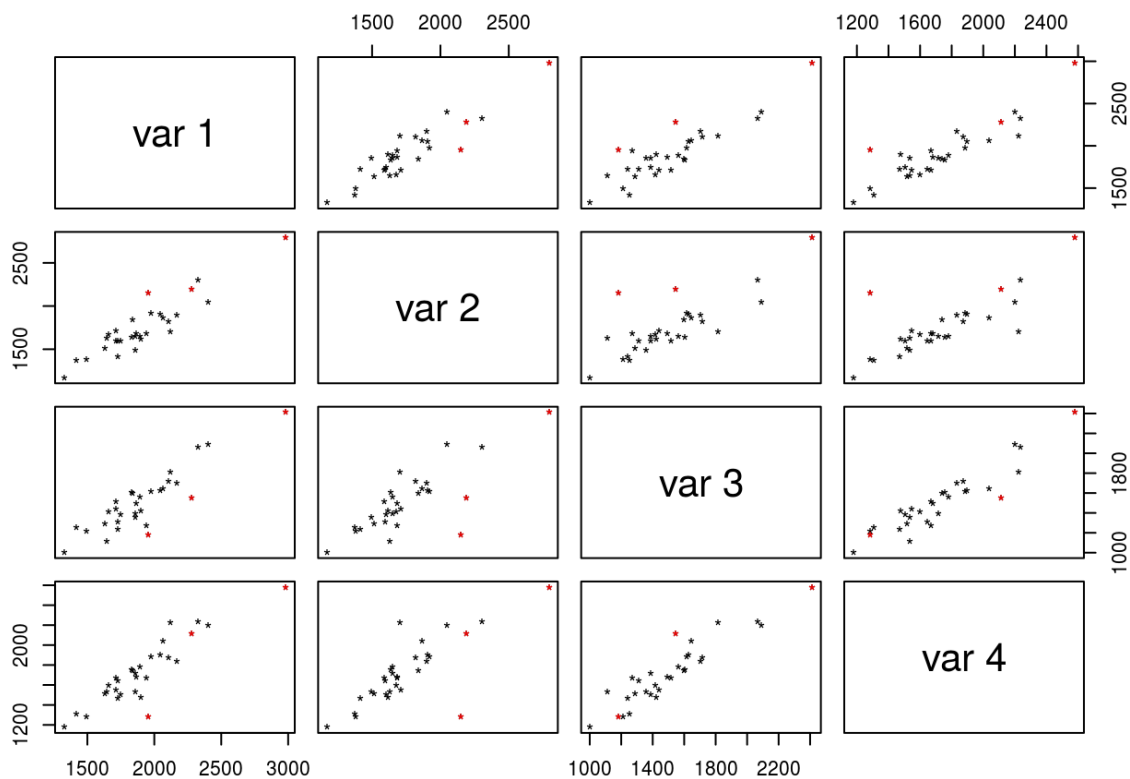
```
## [1] 1906.100 1749.533 1509.133 1724.967
```

A matriz de covariância Σ é:

```
##
## 105616.30  94613.53 87289.71  94230.73
##  94613.53 101510.12 76137.10  81064.36
##  87289.71  76137.10 91917.09  90352.38
##  94230.73  81064.36 90352.38 104227.96
```

Encontrando os registros de stiffness que são considerados anomalias:

```
anomalies <- mahalanobis(x, mu, sigma) > qchisq(0.95, 4)
n <- nrow(x)
nAnom <- sum(anomalies)
pairs(rbind(x, x[anomalies,]), pch="*", col=rep(c("black", "red"), c(n, nAnom)))
```



Questão 7

```
head(iris)
```


Sepal.Length	Sepal.Width	Petal.Length	Petal.Width	Species
--------------	-------------	--------------	-------------	---------

6 rows

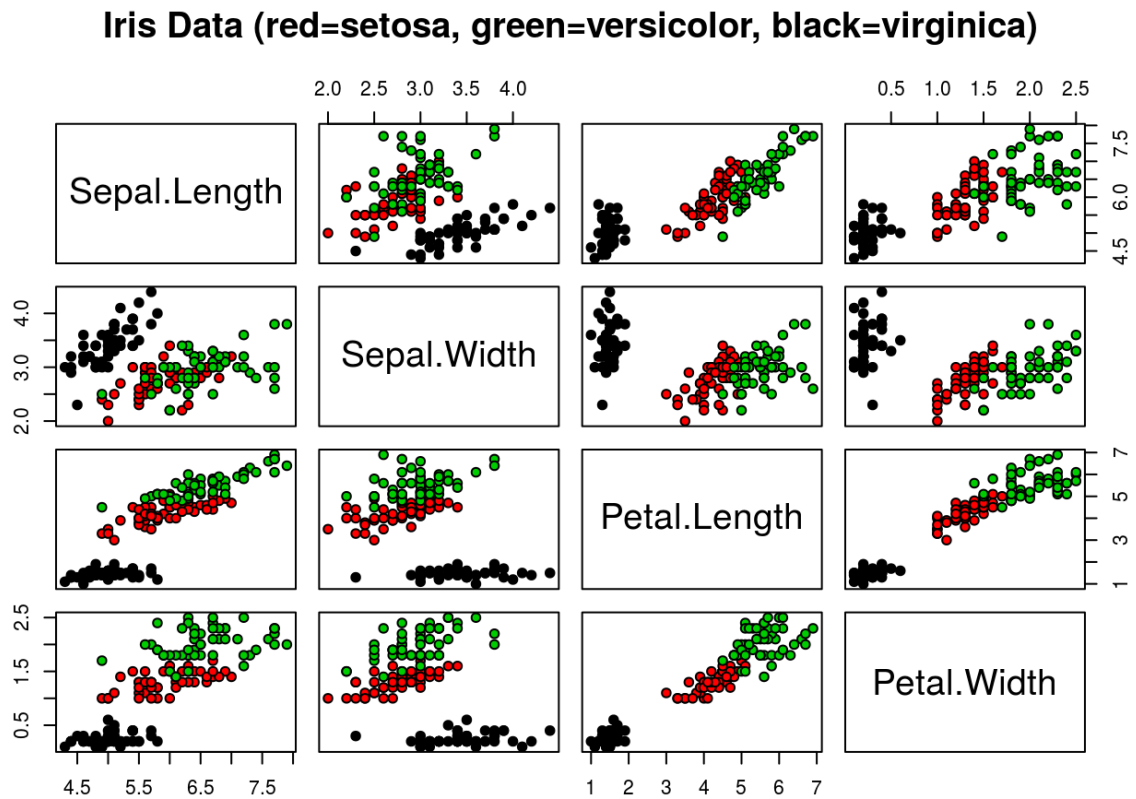
```
dim(iris)
```

```
## [1] 150 5
```

```
pairs(iris[,1:4])
```

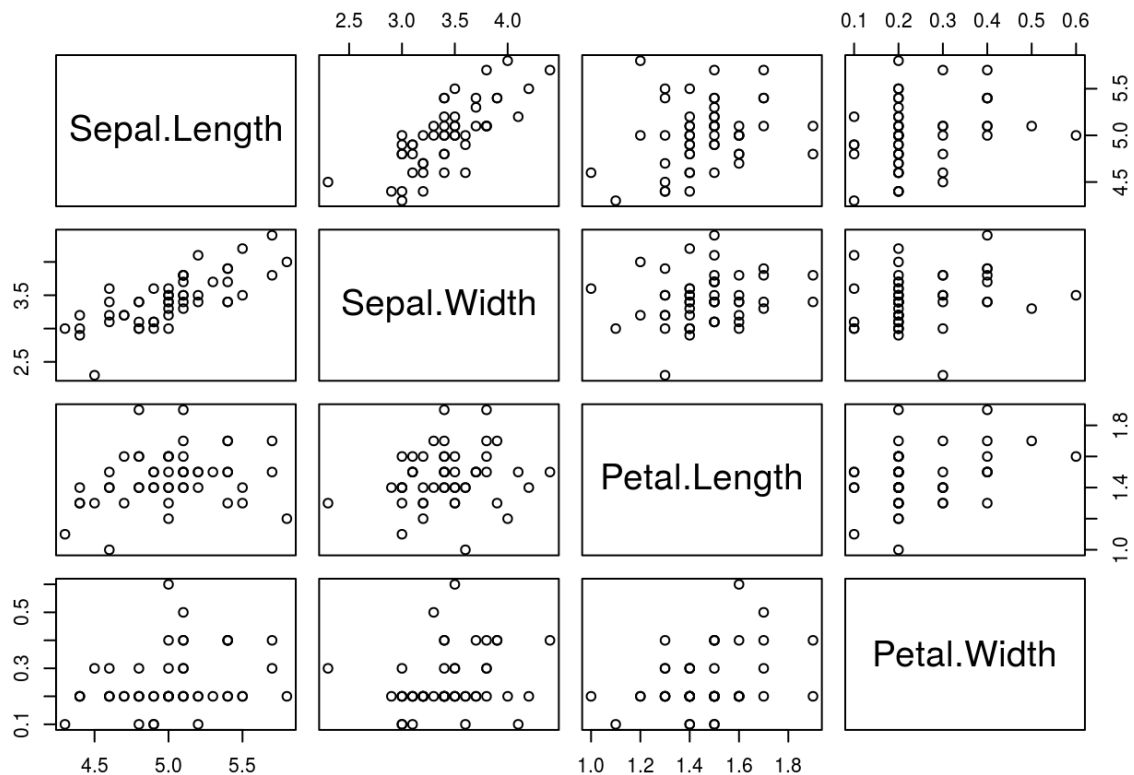


```
titulo = "Iris Data (red=setosa, green=versicolor, black=virginica)"  
pairs(iris[,1:4],main=titulo, pch=21, bg = iris$Species)
```



Analizando a espécie setosa:

```
setosa <- iris[iris$Species == "setosa", 1:4]  
pairs(setosa) # plots de pares das 4 variaveis
```



```
mu <- apply(setosa, 2, mean) # media aritmetica de cada variavel
sigma <- cov(setosa) # estimativa da matriz de covariancia
rho <- cor(setosa) # estimativa da matriz de correlacao
```

a. As estimativas para μ , Σ e ρ são:

```
##  $\mu \approx$ 
##
```

```
## Sepal.Length Sepal.Width Petal.Length Petal.Width
##          5.006          3.428          1.462          0.246
```

```
##
##  $\Sigma \approx$ 
```

```
##
##  0.12424898 0.099216327 0.016355102 0.010330612
##  0.09921633 0.143689796 0.011697959 0.009297959
##  0.01635510 0.011697959 0.030159184 0.006069388
##  0.01033061 0.009297959 0.006069388 0.011106122
```

```
##
## p≈
```

```
##
## 1.0000000 0.7425467 0.2671758 0.2780984
## 0.7425467 1.0000000 0.1777000 0.2327520
## 0.2671758 0.1777000 1.0000000 0.3316300
## 0.2780984 0.2327520 0.3316300 1.0000000
```

b. Analisando a matriz de correlação, vemos que as variáveis mais correlacionadas são o comprimento e a largura da sépala ($\rho=0.74$) e as variáveis menos correlacionadas são o comprimento da pétala e a largura da sépala.

c. Para determinarmos a distribuição marginal de $\mathbf{X}^* = (X_1, X_2)$ basta observarmos as posições correspondentes no vetor esperado e na matriz de covariância de \mathbf{X} .

$$\mathbf{X}^* \sim N_2 \left(\begin{pmatrix} 5.006 \\ 3.428 \end{pmatrix}, \begin{bmatrix} 0.124 & 0.099 \\ 0.099 & 0.144 \end{bmatrix} \right)$$

d. A distribuição condicional de \mathbf{X}^* quando $X_3 = x_3$ e $X_4 = x_4$ é da forma $N_2(\mathbf{m}, \mathbf{V})$, onde:

$$\mathbf{m} = \begin{pmatrix} 5.006 \\ 3.428 \end{pmatrix} + \begin{bmatrix} 0.399 & 0.712 \\ 0.247 & 0.702 \end{bmatrix} \begin{pmatrix} x_3 - 1.462 \\ x_4 - 0.246 \end{pmatrix}$$

Conhecendo os valores de $x_3 = 1.8$ e $x_4 = 0.6$ temos:

```
## m =
##
```

```
## 5.393
## 3.76
```

A matriz de covariância é dada por:

$$\mathbf{V} = \begin{bmatrix} 0.124 & 0.099 \\ 0.099 & 0.144 \end{bmatrix} - \begin{bmatrix} 0.016 & 0.010 \\ 0.012 & 0.009 \end{bmatrix} \begin{bmatrix} 0.030 & 0.006 \\ 0.006 & 0.011 \end{bmatrix}^{-1} \begin{bmatrix} 0.016 & 0.012 \\ 0.010 & 0.009 \end{bmatrix}$$

$\mathbf{V} =$

```
##
## 0.110 0.088
## 0.088 0.134
```

e. Sabemos que a distribuição condicional de $\mathbf{X}^* = (X_1, X_2)|X_3 = x_3$ continuará sendo uma normal multivariada da forma $N_2(\mathbf{m}, \mathbf{V})$, onde precisamos encontrar \mathbf{m} e \mathbf{V} . Utilizamos as fórmulas conhecidas, temos então:

$$\mathbf{m} = \begin{pmatrix} \mu_1 \\ \mu_2 \end{pmatrix} + \begin{bmatrix} \sigma_{13} \\ \sigma_{23} \end{bmatrix} [\sigma_{33}]^{-1} (1.8 - \mu_3)$$

$$\mathbf{m} = \begin{pmatrix} 5.006 \\ 3.428 \end{pmatrix} + \begin{pmatrix} 0.180 \\ 0.135 \end{pmatrix} = \begin{pmatrix} 5.186 \\ 3.563 \end{pmatrix}$$

e

$$\mathbf{v} = \begin{bmatrix} \sigma_{11} & \sigma_{12} \\ \sigma_{21} & \sigma_{22} \end{bmatrix} - \begin{bmatrix} \sigma_{13} \\ \sigma_{23} \end{bmatrix} [\sigma_{33}]^{-1} \begin{bmatrix} \sigma_{31} & \sigma_{32} \end{bmatrix}$$

v

$$= \begin{bmatrix} 0.124 & 0.099 \\ 0.099 & 0.144 \end{bmatrix} - \begin{bmatrix} 0.016 \\ 0.012 \end{bmatrix} [0.030]^{-1} \begin{bmatrix} 0.016 & 0.012 \end{bmatrix}$$

$$= \begin{bmatrix} 0.115 & 0.093 \\ 0.093 & 0.139 \end{bmatrix}$$

f. Aplicando os mesmos procedimentos do item anterior, temos que:

$$\text{onde } \mathbf{m} = \begin{pmatrix} 5.006 \\ 3.428 \end{pmatrix} + \begin{bmatrix} 0.010 \\ 0.009 \end{bmatrix} [0.011]^{-1} (0.6 - 0.246)$$

m =

```
##
## 5.328
## 3.718
```

e

v

$$= \begin{bmatrix} 0.124 & 0.099 \\ 0.099 & 0.144 \end{bmatrix} - \begin{bmatrix} 0.010 \\ 0.009 \end{bmatrix} [0.011]^{-1} \begin{bmatrix} 0.010 & 0.009 \end{bmatrix}$$

$$= \begin{bmatrix} 0.115 & 0.091 \\ 0.091 & 0.136 \end{bmatrix}$$

g. Analisando os resultados anteriores, vemos que saber o valor de X_4 diminui mais a incerteza sobre o valor de X_2 do que conhecer o valor de X_3 . Desta forma, prefiro conhecer X_4 pois ela tem maior poder de influência sobre a variável X_2 . É importante observar que os valores específicos 3/i> e 4/i> não tem influência sobre as variâncias condicionais, o que faz com que seja melhor conhecer algum valor de X_3 do que de X_4 independentemente do número conhecido.

h. Comparando as variâncias condicionais quando conhecemos X_3 e X_4 temos:

$$V(X_2 | X_3 = 1.8, X_4 = 0.6) = 0.134$$

$$V(X_2 | X_4 = 0.6) = 0.136$$

Vemos que adicionar informação sobre a variável X_3 reduz a variância de X_2 em apenas 0.002, quando o valor de X_4 é conhecido.

Questão 8

- a. *Afirmativa Falsa, uma vez que se $(x_1 - \mu_1) / \sqrt{\sigma_{11}} = 2$ temos que $\mu_c = \mu_2 + 2\rho\sqrt{\sigma_{22}}$. Como $|\rho| < 1$, $2\rho\sqrt{\sigma_{22}} < 2\sqrt{\sigma_{22}}$, ou seja, o valor esperado μ_c não varia por mais de dois desvios-padrão.*
- b. *a variancia condicional $V(X_2 | X_1 = x) = \sigma_c^2 = \sigma_{22}(1-\rho^2)$, que independe de x*
- c. *Verdadeiro, pois a variância de X_2 condicionada em X_1 é igual a $\sigma_{22}(1-\rho^2)$ que é sempre menor que σ_{22} , já que $\rho^2 < 1$.*
- d. *Verdadeiro, pois temos que:*

$$\mu_c = \mu_2 + \rho \sqrt{\frac{\sigma_{22}}{\sigma_{11}}} (x_1 - \mu_1)$$

sabemos que μ_2 e $\rho\sqrt{(\sigma_{22} / \sigma_{11})}$ são constantes, o que significa que a equação encontrada para μ_c é uma função linear de x_1